

CENTRO UNIVERSITÁRIO FEI

VICTOR BIAZON

RA: 119.115-4

**RELATÓRIO IV – PROGRAMAÇÃO CIENTÍFICA  
DESCIDA DE GRADIENTE**

SÃO BERNARDO DO CAMPO

2019

VICTOR BIAZON

RA: 119.115-4

**RELATÓRIO IV – PROGRAMAÇÃO CIENTIFICA**  
**DESCIDA DE GRADIENTE**

Relatório de desenvolvimento do algoritmos descida de gradiente, desenvolvido pelo aluno Victor Biazon, RA 119.115-4, para disciplina PEL216 – Programação Cientifica, ministrada pelo professor Reinaldo Bianchi.

São Bernardo do Campo

2019

## **Sumário:**

<b>Motivação .....</b>	<b>4</b>
<b>Objetivo: .....</b>	<b>4</b>
<b>Teoria .....</b>	<b>5</b>
<b>Implementação.....</b>	<b>6</b>
<b>Pseudo-código – Descida de Gradiente .....</b>	<b>6</b>
<b>Experimentos e resultados .....</b>	<b>7</b>
<b>Trabalhos correlatos .....</b>	<b>11</b>
<b>Conclusão .....</b>	<b>12</b>
<b>Referências bibliográficas.....</b>	<b>13</b>

## **Motivação**

Implementação de algoritmo para encontrar o mínimo local de funções matemáticas.

## **Objetivo:**

Desenvolver o algoritmo que através de iterações realiza o cálculo do ponto mínimo local de uma função matemática através do uso da descida de gradiente baseada no uso de derivadas da função para encontrar tal objetivo.


## Teoria

Para se encontrar o mínimo de uma função utilizando a descida de gradiente é necessário calcular a derivada de tal função para a condição inicial e ajusta seu valor iterativamente até que se encontre o ponto onde a derivada é igual a zero (ou muito próximo disso, já que pelas iterações geralmente atingir o valor zero é impossível).

No entanto é extremamente importante observar qual será a condição inicial utilizada já que para alguns casos a escolha errônea de tal condição pode levar a uma iteração não convergente, ou seja, que estoura para o infinito negativo.


Também é importante observar a taxa de aprendizado, que deve ser adequada ao problema. Se por exemplo se utilizar uma taxa de aprendizado muito pequena, o problema levará muito tempo para ser solucionado. Por outro lado com uma taxa grande demais o problema pode não chegar a convergir, pois passa de um lado para o outro do gradiente e não consegue atingir o ponto de mínimo, ou no pior caso, se distancia cada vez mais do objetivo.

Abaixo está ilustrado como as iterações chegam ao ponto de mínimo utilizando a descida de gradiente, sendo a reta tangente a função a representação gráfica da derivada da função naquele ponto.



[1]

Abaixo uma ilustração das taxas de aprendizado:



[2]

## Implementação

### Pseudo-código – Descida de Gradiente

```
DescidaGradiente()
{
    x = x0; //x recebe o valor inicial x0
    f = Funcao(x); //calcula de f0
    f_linha = Derivada(x); //derivada da função em X

    while (abs(f_linha) > 0.0000001) { //avalia enquanto o modulo da
derivada de f for maior que um número muito próximo de 0, pois não é possível
chegar ao zero.
        s = Derivada(x); //calcula derivada da função em x
        x = x - taxa_ap * s; //realiza o desconto da derivada
multiplicada pela taxa de variação
        f_linha = Derivada(x); //calcula a derivada novamente para
ser avaliada pelo while
    }
    Imprime (x, f) // mostra o valor de x, e da funcao f, onde o mínimo
local ocorre.
```

O pseudocódigo acima é uma generalização, onde as funções “Funcao” e “Derivada” são cálculos dependentes da função a ser avaliada.

## Experimentos e resultados

Para testar o algoritmo foram propostas duas funções e duas taxas de aprendizado.

Sendo elas:

- a)  $x^2$  com condição inicial  $x_0 = 2$ ;
- b)  $x^3 - 2x^2 + 2$  com condição inicial  $x_0 = 2$ ;

E taxas de aprendizado 0,1 e 1.

Com isso tivemos os seguintes resultados:

com condição inicial  $x_0 = 2$  e taxa de aprendizado 0.1.

Iniciando as iterações...

```
X: 1.6 s: 4
X: 1.28 s: 3.2
X: 1.024 s: 2.56
X: 0.8192 s: 2.048
X: 0.65536 s: 1.6384
X: 0.524288 s: 1.31072
X: 0.41943 s: 1.04858
X: 0.335544 s: 0.838861
X: 0.268435 s: 0.671089
X: 0.214748 s: 0.536871
X: 0.171799 s: 0.429497
X: 0.137439 s: 0.343597
X: 0.109951 s: 0.274878
X: 0.0879609 s: 0.219902
X: 0.0703687 s: 0.175922
X: 0.056295 s: 0.140737
X: 0.045036 s: 0.11259
```

Vindo a convergir em:

```
X: 6.76921e-14 s: 1.6923e-13
X: 5.41537e-14 s: 1.35384e-13
X: 4.3323e-14 s: 1.08307e-13
X: 3.46584e-14 s: 8.66459e-14
X: 2.77267e-14 s: 6.93167e-14
X: 2.21814e-14 s: 5.54534e-14
X: 1.77451e-14 s: 4.43627e-14
X: 1.41961e-14 s: 3.54902e-14
X: 1.13569e-14 s: 2.83921e-14
X: 9.08548e-15 s: 2.27137e-14
X: 7.26839e-15 s: 1.8171e-14
X: 5.81471e-15 s: 1.45368e-14
X: 4.65177e-15 s: 1.16294e-14
O mínimo local da função  $x^2$  se encontra em  $x$ : 4.65177e-15 e neste ponto a função vale: 2.16389e-29
Arredondando  $x$ : 0 e o valor da função: 0
```


Desta forma pudemos extrair da execução que o ponto mínimo ocorre na função  $x^2$  quando:  
 $x = 0$ , resultando em  $y = 0$ .

Já para a mesma função mas com taxa de aprendizado = 1:

As iterações retornam:

```
X: 2 s: -4
X: -2 s: 4
X: 2 s: -4
X: -2 s: 4
X: 2 s: -4
X: -2 s: 4
X: 2 s: -4
X: -2 s: 4
X: 2 s: -4
X: -2 s: 4
X: 2 s: -4
X: -2 s: 4
X: 2 s: -4
X: -2 s: 4
X: 2 s: -4
X: -2 s: 4
```

Nesta pode-se notar que o  $x$  varia entre 2 e -2 apenas, sendo assim o valor da taxa de aprendizado causou uma impossibilidade de convergência pois o valor de  $x$  nunca deixará de mudar de 2 para -2 e vice-versa. Com isto a taxa de aprendizado de 1, impossibilita a solução. Tal variação de posições é ilustrada na imagem abaixo.



[3]

Como podemos ver a acima a imagem confirma o ponto de mínimo da função ocorrendo no ponto  $x = 0$ .



Avaliando agora a função  $x^3 - 2x^2 + 2$  com condição inicial  $x_0 = 2$  e taxa de aprendizado 0.1.

As iterações rapidamente convergem para:


```
X: 1.6 s: 4
X: 1.472 s: 1.28
X: 1.41076 s: 0.612352
X: 1.37799 s: 0.327713
X: 1.35953 s: 0.184624
X: 1.34885 s: 0.10685
X: 1.34257 s: 0.062773
X: 1.33885 s: 0.0371977
X: 1.33663 s: 0.022154
X: 1.33531 s: 0.0132338
X: 1.33452 s: 0.00791934
X: 1.33404 s: 0.00474409
X: 1.33376 s: 0.00284376
X: 1.33359 s: 0.00170528
X: 1.33349 s: 0.00102282
X: 1.33343 s: 0.000613568
X: 1.33339 s: 0.000368095
X: 1.33337 s: 0.000220841
X: 1.33335 s: 0.000132499
X: 1.33335 s: 7.94971e-05
X: 1.33334 s: 4.76975e-05
X: 1.33334 s: 2.86182e-05
X: 1.33334 s: 1.71708e-05
X: 1.33333 s: 1.03025e-05
X: 1.33333 s: 6.18147e-06
X: 1.33333 s: 3.70888e-06
X: 1.33333 s: 2.22533e-06
X: 1.33333 s: 1.33519e-06
X: 1.33333 s: 8.01117e-07
X: 1.33333 s: 4.8067e-07
X: 1.33333 s: 2.88402e-07
X: 1.33333 s: 1.73041e-07
X: 1.33333 s: 1.03825e-07
O mínimo local da funcao x^3-2*x^2+2 se encontra em x: 1.33333 e neste ponto a funcao vale: 0.814815
```

Desta forma pudemos extrair da execução que o ponto mínimo local ocorre na função

$x^3 - 2x^2 + 2$  quando:

$x = 1.333$ , resultando em  $y = 0,8148$ .

Como podemos ver abaixo a função plotada confirma o ponto de mínimo local.



[4]

Mínimo

Agora analisando a mesma função com taxa de aprendizado = 1:

As iterações resultam em:

```
X: -2 s: 4
X: -22 s: 20
X: -1562 s: 1540
X: -7.32734e+06 s: 7.32578e+06
X: -1.6107e+14 s: 1.6107e+14
X: -7.78305e+28 s: 7.78305e+28
X: -1.81728e+58 s: 1.81728e+58
X: -9.90748e+116 s: 9.90748e+116
X: -2.94474e+234 s: 2.94474e+234
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
X: -inf s: inf
```

Como pode-se notar rapidamente o x tende a infinito negativo com inclinação infinita. Isto se deve a esta função ter como característica tender ao infinito negativo para um limite:

$\lim_{n \rightarrow -\infty} x^3 - 2x^2 + 2$ . Por isso ao utilizar esta taxa de aprendizado grande demais o algoritmo

“pulou” para outra descida da função que no caso não encontra ponto onde a derivada é zero pois seu valor diminui cada vez mais.




Ilustração da iteração com taxa de aprendizado = 1.

## **Trabalhos correlatos**

### **Stochastic Gradient Descent as Approximate Bayesian Inference**

MANDT, Stephan; HOFFMAN, Matthew D.; BLEI, David M.; 2017

<http://www.jmlr.org/papers/volume18/17-214/17-214.pdf>

### **Globally Optimal Gradient Descent for a ConvNet with Gaussian Inputs**

BRUTZKUS, Alon; GLOBERSON, Amir; 2017

<https://pdfs.semanticscholar.org/fc75/6b45678ef7ffc1a796de62365013011b659e.pdf>

## **Conclusão**

Com sete experimento pudemos concluir que a descida de gradiente, para encontrar numericamente o ponto mínimo de uma função é extremamente útil quando não se é possível determinar formalmente, ou analiticamente, a função matemática em questão. Desta forma é possível soluções empíricas não necessitando modelar matematicamente o problema.

Para as duas funções propostas foi evidenciado a grande dependência para o sucesso do êxito do algoritmo a determinação do ponto de início das iterações, ou seja as condições iniciais. E também é importantíssimo ressaltar a relevância de se determinar uma taxa de aprendizado coerente para que o algoritmo chegue à solução rapidamente e possa convergir em um resultado. Sendo que para taxas muito baixas se leva muito tempo, e taxas muito grandes o algoritmo não converge ou se perde.

## Referências bibliográficas

- [1] <http://deeplearningbook.com.br/aprendizado-com-a-descida-do-gradiente/>
- [2] <https://matheusfacure.github.io/2017/02/20/MQO-Gradiente-Descendente/>
- [3] <https://www.wolframalpha.com/input/?i=x%5E2>
- [4] <https://www.wolframalpha.com/input/?i=x%5E3-2x%5E2%2B2>